# In Search of Lost Domain Generalization

What goes next?

# Авторы: Ishaan Gulrajani

- Делает PhD в Стэнфорде
- Успел поработать в Facebook Al Research, Google Brain и Mila институт Al исследований в Монреале
- В основном занимается GAN'ами и Domain Generalization, но далеко не только этим
- Первые статьи были по NLP, в частности Dynamic
   Метогу для языковых моделей



#### Авторы: David Lopez-Paz

- Facebook Al Research
- PhD в Институте Макса Планка и Кэмбридже
- Стажировался в European Space Agency, Google Research и the Red Bull Formula 1 team (goes brrrr).
- В основном занимается Domain Generalization и в целом переносом знаний в нейросетях в той же дистилляции





# Авторы

Годом ранее вдвоём участвовали в написании <u>Invariant Risk Minimization</u> [2019], так что отчасти в этой статье они занимаются критикой своего предыдущего подхода.



Domain generalization algorithms	Data manipulation (Sec. 4.1)	Data augmentation  Adversarial data augmentation: CrossGrad [37]/ ADA [38]/ DDAIG [39]  M-ADA [40]/ UFDN [41]/ UNVP [42]/ L2A-OT [43]/ M3L [44]/ FSUS [45]/ ADAGE [46]/
	Representation learning (Sec. 4.2)  Learning strategy (Sec. 4.3)	Data generation  DomainMix [47] / MixALL [48] / MixStyle [49] / DeGIA [50] / MBDG [51] / PDEN [52] / SFA [53] / OpenDG [54] / FACT [55] / [56, 57, 36, 58, 59]    Kernel methods: MTL [6, 60] / Multi-TCA [61] / DICA [27] / UDICA [62] / CIDG [63] / SCA [64] / ESRand [65] / MDA [66] / [28]
		Explicit feature alignment: MTAE [67]/ CCSA [68]/ BNE [69]/ SNR [70, 71]/ MMD-AAE [72]/ DDGFD [73]/ DSDGN [74]/ DG-YOLO [75]/ MatchDG [76]/ DSON [77]/ DFDG [78]/ DSAF [79]/ AdaRNN [80]/ ASR-Norm [81]/ RNA-Net [82]/ FAR [83]/ LAG [84]/ [85, 86, 87, 88, 89, 90]
		Domain adversarial learning: DANN [91, 92]/ MMD-AAE [72]/ DLOW [93]/ CIAN [94]/ ER [95]/ MADDG [96]/ FSUS [45]/ MMLD [97]/ DANNCE [98]/ CAADG [99]/ SSDG [100]/ AdaRNN [80] ASR-Norm [81]/ SADG [101]/ [102, 103]
		[104]/IB-IRM [105]/VRex [106]/ReLIC [107]/[108, 109, 110, 111, 112]  [Multi-component analysis: LRE-SVM [113, 114]/ UndoBias [115]/ MVDG [116]/ CSD [117]/ [Domain2Vec [118, 119]/ DCAC [120]/ FLUTE [121]/ [122, 2, 123]
		Feature disentanglement  Generative modeling: DIVA [124]/ DAL [125]/ M-ADA [40]/ DDG [126]/ SagNet [127]/ GILE [128] RobustNet [129]/ [130]  Causality-inspired methods: MatchDG [76]/ Deep CAMA [131]/ CSG [132]/ LaCIM [133]/
		StableNet [134] / [107, 135, 136]  (Ensemble learning) — D-SAM [137] / DAEL [8] / COPA [138] / [139, 140, 141, 142]
		Meta-learning MLDG [17] / MetaReg [18] / FC [19] / MASF [143] / MetaVIB [20] / DADG [144] / DGSML [145] / M3L [44] / Epi-FCR [146] / [147, 148, 149]
		Gradient operation RSC [150]/ Fish [151]/ Fishr [152]/ NCDG [153]/ KDDG [154]  Distributionally robust optimization VRex [106]/ JTT [155]/ GroupDRO [156]/ [157, 158]
		Self-supervised learning — [159]/ SelfReg [160]/ [161, 162]
		Others Random forest [163]/Shape-invariant [164]/Lottery ticket hypothesis [165]/Flat minima [166]/ Metric learning [167]

Domain randomization: DRPC [29]/ SDR [30]/ FSDR [31]/ [32, 33, 34, 35, 36]

# Domain Invariant Representation Learning

Данная группа методов строит представления  $\phi(X^d)$  данных различных доменов в общем признаковом пространстве.

- <u>Domain Adversarial Training</u> обучаем состязательную нейронку предсказывать, из какого домена пришли преобразованные данные
- Invariant Risk Minimization обучаем такое представление данных, что лучший линейный предиктор поверх  $\phi(X^d)$  не будет различаться между доменами. Этот подход мотивирован нахождением корреляций между данными и лейблами.
- В более современной <u>работе</u> говорят, что кроме сближения  $\phi(X^d)$  для разных доменов нужно учитывать гладкость полученных представлений.

# А что дальше? Алгоритмы

- Последняя обзорная статья по области вышла в 2022
- Для Domain Generalization примерно на тех же датасетах ничего не поменялось сильного отрыва различных алгоритмов от ERM нет
- Однако для Domain Adaptation смежной задачи, где в процессе обучения доступна выборка на целевом домене, ситуация другая методы Domain Adversarial Training работают значительно лучше
- И да, в Domain Generalization зачастую читерят, сравнивая модели на тестовом домене. Но за счет ограниченного числа обращений к нему (как в этой статье) особой утечки данных вроде как не происходит.

#### А что дальше? Алгоритмы

Один из способов улучшить качество - обучение ансамбля моделей с последующим отбором подходящих к определенным данным: <u>SIMPLE</u>

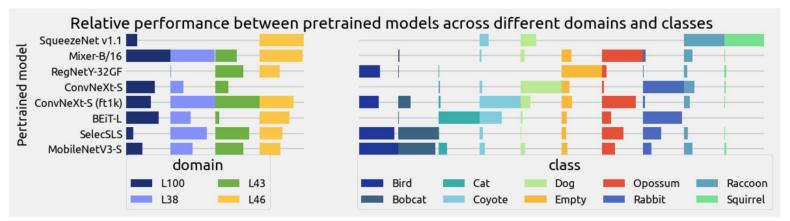
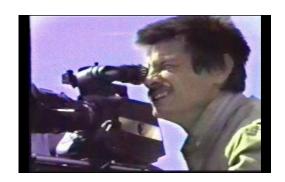


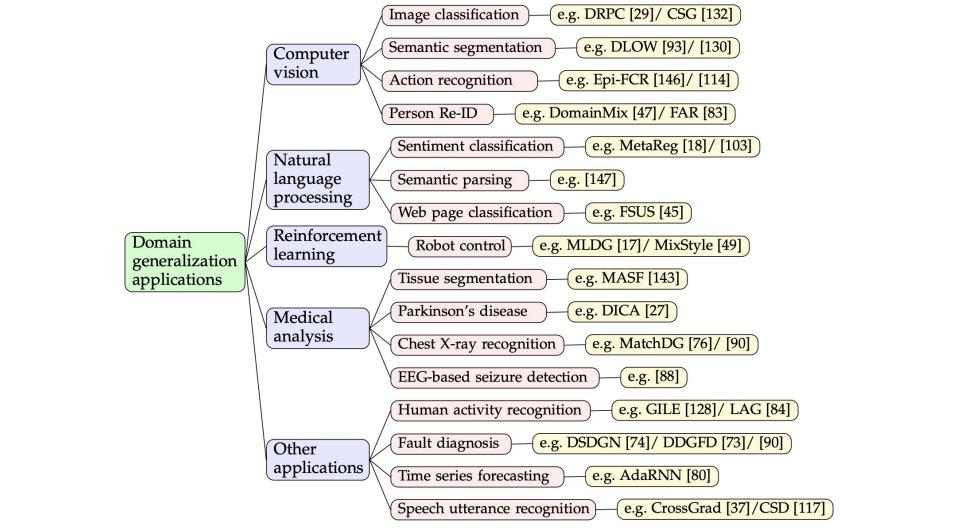
Figure 1: Classification performance comparison of pretrained models in different domains and different classes of the TerraIncognita dataset (Beery et al., 2018). For clarity of presentation, only partial results are shown. The complete results can be found in Appendix A.4.

# А что дальше? Данные

- Все датасеты для сравнения на задачи Computer Vision. Пробовали ли в domain generalization в других областях?
- Да, пробовали. Но, как правило, адаптируя архитектуры моделей под конкретную задачу. Настолько общего сравнения всех стадий пайплайна и уж тем более выводов по другим областям нет :(







# А что дальше? Данные

Для увеличения количества данных и сближения исходных доменов с целевым зачастую используют аугментации данных или генерируют новые.

Такими методами мы симулируем общее распределение данных с какой-то погрешностью и нет четких гарантий, что мы в целом двигаем модель в сторону уменьшения риска на целевом, неизвестном домене.

"In god we trust. All others must bring data."

W. Edwards Deming



# THATETURNS

широкие обобщения

INTO

сомнительные выводы

# Материалы

- In Search of Lost Domain Generalization [2020]
- Generalizing to Unseen Domains: A Survey on Domain Generalization [2022]
- <u>Domain-Adversarial Training of Neural Networks [2016]</u>
- Invariant Risk Minimization [2019]
- On the benefits of representation regularization in invariance based domain generalization [2021]
- SIMPLE [2023]