



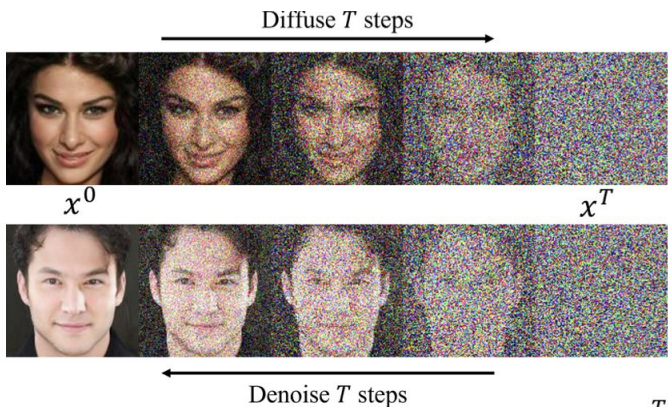
# (Consistency Models)

## Fast sampling

Elnikov Vladislav

# Problem

Sampling process is slow because it requires hundreds to thousands of network evaluations to emulate a continuous process defined by differential equations.



# Напомним наши результаты

## ImageNet 64 × 64

PD <sup>†</sup> (Salimans & Ho, 2022)	1	15.39	0.59	0.62
DFNO <sup>†</sup> (Zheng et al., 2022)	1	8.35		
<b>CD<sup>†</sup></b>	1	<b>6.20</b>	0.68	0.63
PD <sup>†</sup> (Salimans & Ho, 2022)	2	8.95	0.63	<b>0.65</b>
<b>CD<sup>†</sup></b>	2	<b>4.70</b>	<b>0.69</b>	0.64
ADM (Dhariwal & Nichol, 2021)	250	<b>2.07</b>	0.74	0.63
EDM (Karras et al., 2022)	79	2.44	0.71	<b>0.67</b>
BigGAN-deep (Brock et al., 2019)	1	4.06	<b>0.79</b>	0.48
<b>CT</b>	1	13.0	0.71	0.47
<b>CT</b>	2	<b>11.1</b>	0.69	0.56

METHOD	NFE (↓)	FID (↓)	IS (↑)
<b>Diffusion + Samplers</b>			
DDIM (Song et al., 2020)	50	4.67	
DDIM (Song et al., 2020)	20	6.84	
DDIM (Song et al., 2020)	10	8.23	
DPM-solver-2 (Lu et al., 2022)	10	5.94	
DPM-solver-fast (Lu et al., 2022)	10	4.70	
3-DEIS (Zhang & Chen, 2022)	10	<b>4.17</b>	
<b>Diffusion + Distillation</b>			
Knowledge Distillation* (Luhman & Luhman, 2021)	1	9.36	
DFNO* (Zheng et al., 2022)	1	4.12	
1-Rectified Flow (+distill)* (Liu et al., 2022)	1	6.18	9.08
2-Rectified Flow (+distill)* (Liu et al., 2022)	1	4.85	9.01
3-Rectified Flow (+distill)* (Liu et al., 2022)	1	5.21	8.79
PD (Salimans & Ho, 2022)	1	8.34	8.69
<b>CD</b>	1	<b>3.55</b>	<b>9.48</b>
PD (Salimans & Ho, 2022)	2	5.58	9.05
<b>CD</b>	2	<b>2.93</b>	<b>9.75</b>
<b>Direct Generation</b>			
BigGAN (Brock et al., 2019)	1	14.7	9.22
Diffusion GAN (Xiao et al., 2022)	1	14.6	8.93
AutoGAN (Gong et al., 2019)	1	12.4	8.55
E2GAN (Tian et al., 2020)	1	11.3	8.51
ViTGAN (Lee et al., 2021)	1	6.66	9.30
TransGAN (Jiang et al., 2021)	1	9.26	9.05
StyleGAN2-ADA (Karras et al., 2020)	1	2.92	<b>9.83</b>
StyleGAN-XL (Sauer et al., 2022)	1	<b>1.85</b>	
Score SDE (Song et al., 2021)	2000	2.20	<b>9.89</b>
DDPM (Ho et al., 2020)	1000	3.17	9.46
LSGM (Vahdat et al., 2021)	147	2.10	
PFGM (Xu et al., 2022)	110	2.35	9.68
EDM (Karras et al., 2022)	35	<b>2.04</b>	9.84
1-Rectified Flow (Liu et al., 2022)	1	378	1.13
Glow (Kingma & Dhariwal, 2018)	1	48.9	3.92
Residual Flow (Chen et al., 2019)	1	46.4	
GLFlow (Xiao et al., 2019)	1	44.6	
DenseFlow (Grcić et al., 2021)	1	34.9	
DC-VAE (Parmar et al., 2021)	1	17.9	8.20
<b>CT</b>	1	<b>8.70</b>	<b>8.49</b>
<b>CT</b>	2	<b>5.83</b>	<b>8.85</b>

## Early Stop of the Diffusion Process

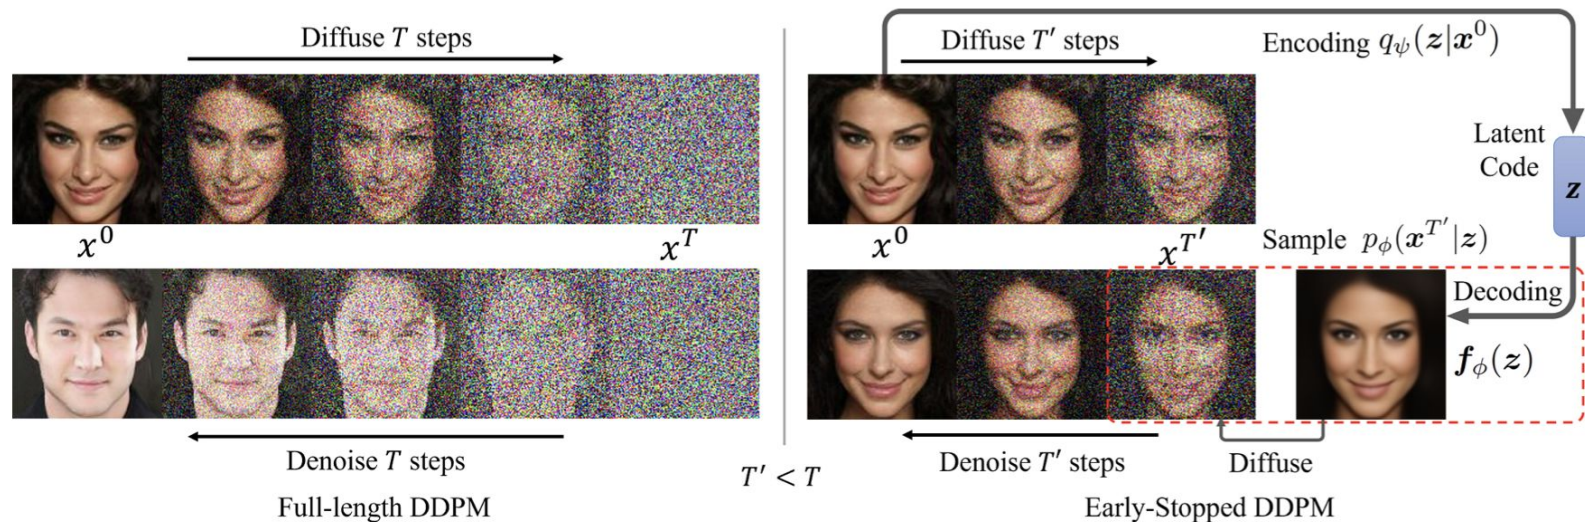


Figure 1: Compare Early-Stopped DDPM (ES-DDPM) with the full-length DDPM.

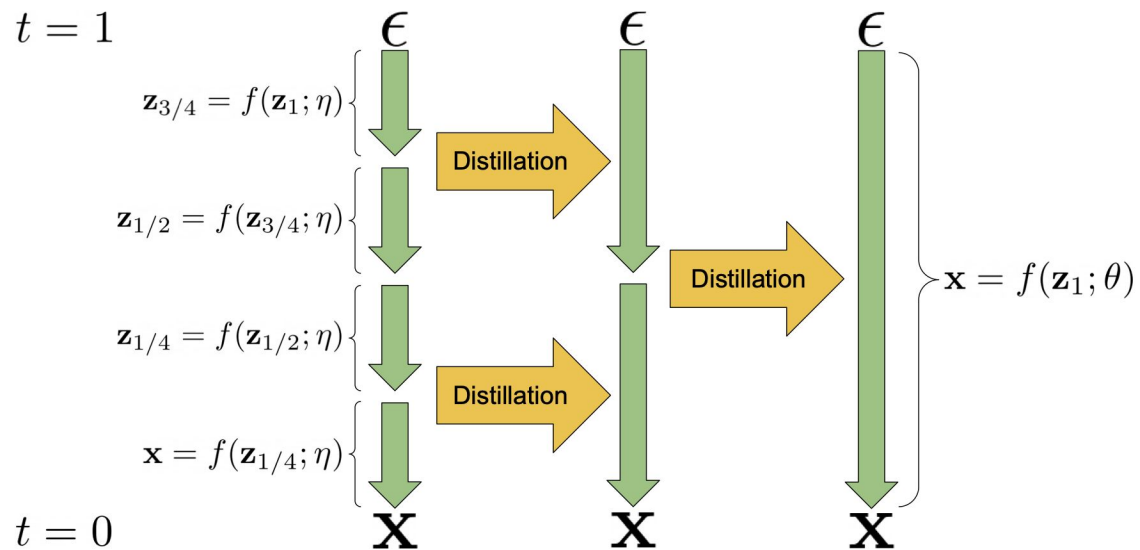
CelebA-64		Method	FID
Hybrid Models		StyleGAN2+100-step ES-DDPM ( <b>Ours</b> )	3.01
		StyleGAN2+200-step ES-DDPM ( <b>Ours</b> )	<b>2.55</b>
		1000-step DiffuseVAE (Pandey et al., 2022)	4.76
Score-based Methods		1000-step DDPM* (Ho et al., 2020)	3.26
		250-step PNDM (Liu et al., 2022)	2.71
		NCSN (Song & Ermon, 2019)	25.30
		NCSNv2 (Song & Ermon, 2020)	10.23
GAN-based Methods		COCO-GAN (Lin et al., 2019)	4.00
		StyleGAN2* (Karras et al., 2020)	4.55
		QA-GAN (Parimala & Channappayya, 2019)	6.42
VAE-based Methods		NCP-VAE (Aneja et al., 2020)	5.25

CelebA-128		Method	FID
Hybrid Models		StyleGAN2+100-step ES-DDPM ( <b>Ours</b> )	<b>1.76</b>
		StyleGAN2+200-step ES-DDPM ( <b>Ours</b> )	1.79
Score-based Methods		1000-step DDPM* (Ho et al., 2020)	5.65
GAN-based Methods		COCO-GAN (Lin et al., 2019)	5.74
		StyleGAN2* (Karras et al., 2020)	2.13
		PresGAN (Dieng et al., 2019)	29.12

Denoising Steps $T'$	0	100	200	300	400	500	600	700	800	900	1000
VAE+ES-DDPM	158.61	49.62	20.88	11.03	5.96	3.69	3.17	3.15	<b>3.12</b>	3.18	3.20
DCGAN+ES-DDPM	33.31	15.54	9.97	7.21	5.49	3.98	3.37	<b>3.13</b>	3.14	3.24	
StyleGAN2+ES-DDPM	7.18	5.52	5.02	4.60	4.03	3.51	3.26	<b>3.11</b>	3.16	3.17	


# Дистилляция










# Результаты

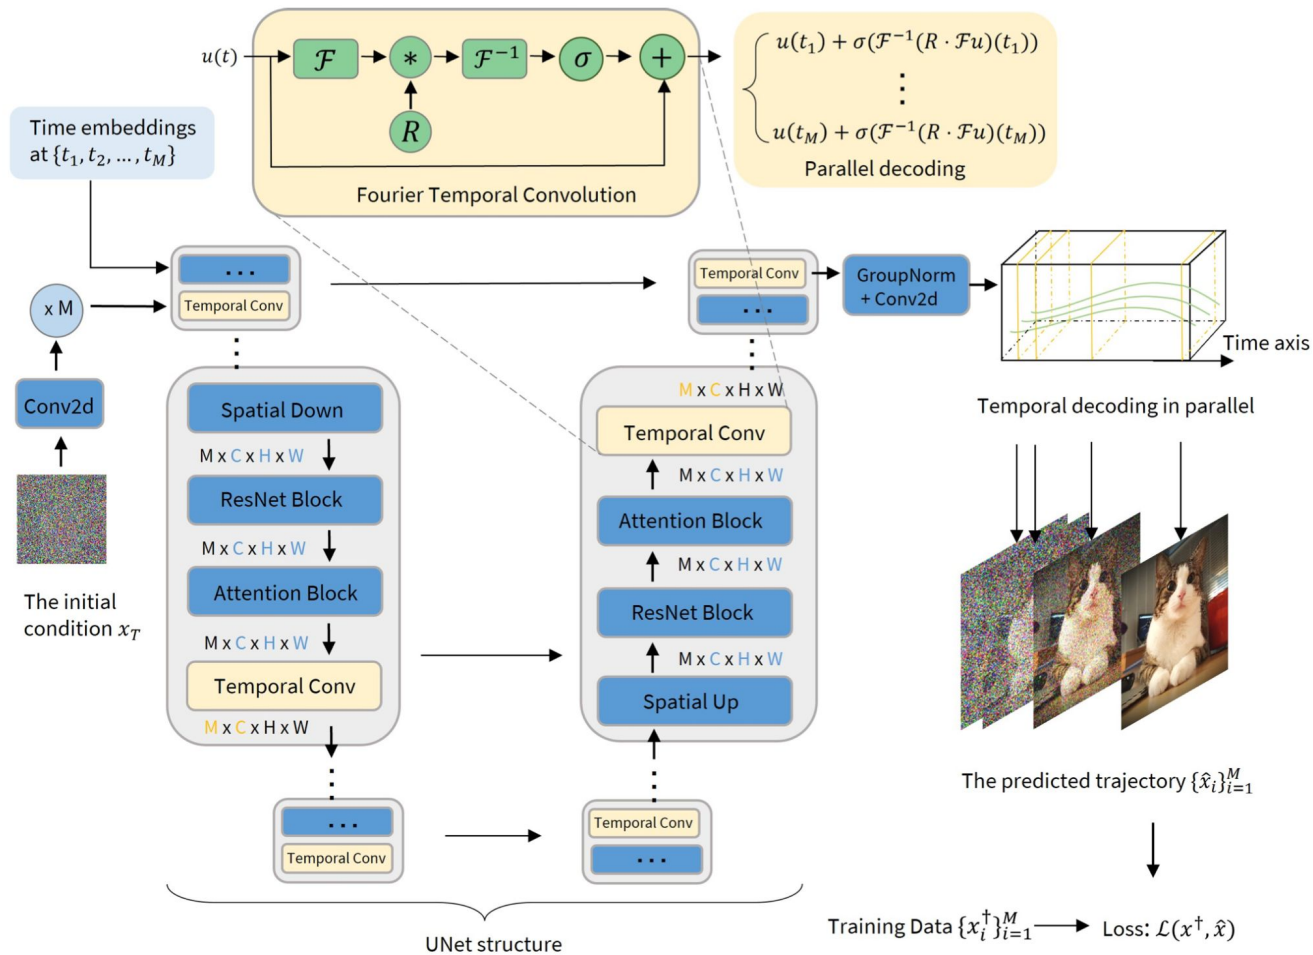
Deterministic sampling:



Stochastic sampling:



# Diffusion Models via Operator Learning





# Как выглядит процесс

$$(\mathcal{T}u)(t) = u(t) + \sigma((\mathcal{K}u)(t))$$

$$(\mathcal{K}u)(t) = \int_D (\mathcal{F}^{-1}R)(\tau)u(t - \tau)d\tau, \forall t \in D.$$

$$R \cdot (\mathcal{F}u)_{j,k} = \sum_{l=1}^d R_{j,k,l}(\mathcal{F}u)_{j,l},$$





## Результат

Method	NFE	FID
Ours	1	<b>3.78</b>
Knowledge distillation (Luhman & Luhman, 2021)	1	9.36
Progressive distillation (Salimans & Ho, 2021)	1	9.12
	2	4.51
	4	3.00

CIFAR-10

Method	Model evaluations	FID score
Ours	1	<b>7.83</b>
Progressive distillation	1	15.99
	2	7.11
	4	3.84

ImageNet-64

# Проблема данных работ по моему мнению

Многие результаты тестируются только на CIFAR-10 и ImageNet-64. Много выводов делается на основе результатов в CIFAR-10, что не может не расстраивать.





## Проблема данных работ по моему мнению

Нет понимания сколько точно работает каждая из моделей, насколько энергозатратны. Нет понимания, что будет лучше сходиться и выдавать лучшую картинку при большем количестве эволюций картинки (NFE - model evolutions).



## Вывод

- Данная тема является очень новой, многие статьи совсем недавние: Diffusion Models via Operator Learning (2023), Consistency Models(2023), PROGRESSIVE DISTILLATION FOR FAST SAMPLING OF DIFFUSION MODELS (2022)
- Нужно более честные сравнения и на большем числе датасетов
- + Данная тема очень перспективна и востребована